

SPRAWOZDANIE - LABORATORIUM NR 10

Poszukiwanie minimum wartości funkcji metodą największego spadku w 2D

Marek Kiełtyka

16 maja 2019

1 Wstęp

1.1 Minimalizacja funkcji

Inaczej nazywana optymalizacją, jej zadaniem jest poszukiwanie odpowiednio minimum lub maksimum funkcji wielu zmiennych. Chodzi o znalezienie punktu spełniającego warunek

$$\min f(\vec{x}) = f(\vec{x}^*) \Leftrightarrow \bigwedge_{\vec{x} \in R^n} f(\vec{x}^*) < f(\vec{x}), \quad \text{gdzie } \vec{x} = [x_1, x_2, \dots, x_n]^T. \quad (1)$$

1.2 Gradient funkcji

Dla funkcji celu $f(\vec{x}) \in C^2$, tj. poszukującej minimum badanej funkcji wejściowej definiuje się funkcję wektorową będącą gradientem funkcji

$$g(\vec{x}) = \nabla f(\vec{x}) = \left[\frac{\partial f(\vec{x})}{\partial x_1}, \frac{\partial f(\vec{x})}{\partial x_2}, \dots, \frac{\partial f(\vec{x})}{\partial x_n} \right]^T. \quad (2)$$

Należy pamiętać, iż gradient skierowany jest zawsze w stronę narastających wartości.

1.3 Pochodna kierunkowa funkcji celu

Różniczkę zupełną funkcji celu definiuje się jako iloczyn skalarny wektorów

$$df = \frac{\partial f}{\partial x_1} dx_1 + \dots + \frac{\partial f}{\partial x_n} dx_n = \nabla f(\vec{x}) dx. \quad (3)$$

Punkty \vec{x} i \vec{x}' nazywane są powiązanymi ze sobą, jeżeli wektor \vec{u} wyznacza kierunek prostej je łączącej, stąd

$$\vec{x}(\lambda) = \vec{x}' + \lambda \vec{u}. \quad (4)$$

Dla bardzo małych zmian wartości λ można uogólnić wzór (4).

$$d\vec{x} = \vec{u} d\lambda \quad (5)$$

Na prostej łączącej ustalone punkty \vec{x} oraz \vec{x}' wartość funkcji celu zależna jest od zmiennej λ .

$$F(\lambda) = f(\vec{x}' + \lambda \vec{u}) = f(\vec{x}) \quad (6)$$

Mając na uwadze powyższe powiązania, oblicza się różniczkę zupełną dla funkcji celu zależnej od λ

$$dF = df = \nabla^T f(\vec{x}) \vec{u} d\lambda. \quad (7)$$

Finalnie, wyrażenie na **pochodną kierunkową funkcji** celu w punkcie \vec{x} dla kierunku \vec{u} jest postaci

$$\frac{dF(\lambda)}{d\lambda} = \left. \frac{df(\vec{x})}{d\lambda} \right|_{\vec{u}} = \nabla^T f(\vec{x}) \vec{u}, \quad (8)$$

jednak korzystając z niej należy ją wyznaczać w każdej iteracji.

1.4 Znajdowanie minimum funkcji przy pomocy pochodnej kierunkowej

Przybliżanie należy rozpocząć z punktu \vec{x}_0 przechodząc przez kolejne punkty $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$ w kierunku spadku wartości funkcji. Pozwala to wyznaczyć ciąg przybliżeń poszukiwanego minimum. Należy przerwać algorytm iteracyjny w momencie, gdy zostanie spełniony jeden z warunków:

1. Norma różnicy wektorów z sąsiednich kroków jest mniejsza od zadanego progu: $\|\vec{x}^{i+1} - \vec{x}^i\| < \epsilon$
2. $\nabla f(\vec{x}) = 0$
3. W kolejnych iteracjach wartość normy $\|\vec{x}^{i+1} - \vec{x}^i\|$ wzrasta, co oznacza brak zbieżności.

1.5 Metoda największego spadku

Wykorzystuje się

- wzór (8) w punkcie \vec{x}' dla wektora kierunkowego \vec{u} o długości równej $\|\vec{u}\| = 1$

$$\left. \frac{df(\vec{x}')}{d\lambda} \right|_{\vec{u}} = \frac{dF(0)}{d\lambda} = \nabla^T f(\vec{x}')\vec{u}, \quad (9)$$

- nierówność Schwartza

$$\nabla^T f(\vec{x}')\vec{u} \geq -\|\nabla^T f(\vec{x}')\| \cdot \|\vec{u}\| = -\|\nabla^T f(\vec{x}')\| = \min. \quad (10)$$

Należy wybrać wektor kierunkowy o postaci

$$\vec{u} = \frac{-\nabla f(\vec{x}')}{\|\nabla f(\vec{x}')\|} \quad (11)$$

aby wskazywał kierunek największego spadku, a pochodna kierunkowa mogła osiągnąć najmniejszą wartość.

$$\frac{dF(0)}{d\lambda} = -\nabla^T f(\vec{x}') \frac{\nabla f(\vec{x}')}{\|\nabla f(\vec{x}')\|} = \min \quad (12)$$

2 Zadanie do wykonania

2.1 Opis problemu

Celem laboratorium było znalezienie minimum zadanej funkcji (13) przy pomocy opisywanej metody

$$f(\vec{r}) = f(x, y) = \frac{5}{2}(x^2 - y)^2 + (1 - x)^2, \quad (13)$$

począwszy od przybliżenia \vec{r}_0 postaci

$$\vec{r}_{i+1} = \vec{r}_i - h \cdot \nabla f(\vec{r})|_{\vec{r}=\vec{r}_i} \quad \text{gdzie } \nabla f(\vec{r}) = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right], \quad (14)$$

które było korygowane w kolejnych iteracjach. Składowe gradientu ze wzoru (14) obliczano numerycznie korzystając z faktu, iż

$$\frac{\partial f(x_i, y_i)}{\partial x} \approx \frac{f(x_i + \Delta x, y_i) - f(x_i - \Delta x, y_i)}{2\Delta x} \quad (15)$$


$$\frac{\partial f(x_i, y_i)}{\partial y} \approx \frac{f(x_i, y_i + \Delta y) - f(x_i, y_i - \Delta y)}{2\Delta y} \quad (16)$$

Przyjęto następujące założenia:


- punkt początkowy $\vec{r}_0 = [-0.75, 1.75]$
- stała $h = 0.01$
- warunki stopu
 - $\|\vec{r}_{i+1} - \vec{r}_i\|_2 < \epsilon$ dla $\epsilon_1 = 10^{-2}$, $\epsilon_2 = 10^{-3}$
 - maksymalna liczba iteracji $maxIter = 1000$
- $\Delta x = \Delta y = \Delta = 10^{-4}$
- $x, y \in [-2, 2]$ z krokiem w obu kierunkach równym 0.02

2.2 Wyniki

Korzystając z programu napisanego w języku C++ i spreparowanego wcześniej skryptu programu *Gnuplot* sporządzono wykresy dla obu przypadków. Rozważano jedną funkcję, zatem dokładne jej minimum było jedno i wyniosło $x_{min} = 1, y_{min} = 1$.



Wykres 1: Położenia kolejnych przybliżeń minimum funkcji $f(x,y)$ w poszczególnych iteracjach dla $\epsilon = 10^{-2}$. W tle: kontury oraz mapa wartości funkcji $f(x,y)$. Program wykonał 37 iteracji.



Wykres 2: Położenia kolejnych przybliżeń minimum funkcji $f(x,y)$ w poszczególnych iteracjach dla $\epsilon = 10^{-3}$. W tle: kontury oraz mapa wartości funkcji $f(x,y)$. Program wykonał 1000 iteracji.

3 Wnioski

Wykresy dowodzą, iż ciężko jest wybrać trafne kryterium zbieżności. Dla pierwszego przypadku nie udało się osiągnąć minimum, choć przebieg (x_i, y_i) zdawał się być na dobrej drodze ku temu. Zmniejszając rząd zbieżności o jeden, zastosowanie znalazł drugi warunek stopu z uwagi na niekończące się oscylacje wokół poszukiwanego minimum. Potwierdziło to również teoretyczny kształt przebiegu (x_i, y_i) dla funkcji z wydłużonym konturem.

Jedynym parametrem, który można by zmodyfikować dla lepszej efektywności obliczeń, jest h . Z racji jego stałości podczas laboratorium skoki nie były regulowane, co znalazło szczególne odbicie w punktach funkcji o niewielkim gradiencie, a w konsekwencji nie osiągnięto zbieżności.

Mimo tych niedoskonałości, metoda największego spadku prowadzi do znalezienia minimum funkcji wielu zmiennych w sposób szybki i prosty.